

北京航空航天大学

博士研究生

《科研进展报告》

拟开题题目或具体方向：

无监督的医学图像检测和分割的研究

姓 名：吴永健

学 号：BY2110209

指导教师：许燕

研究方向：医学图像处理

生物与医学工程学院

目录

一、 研究背景.....	3
1.1 医学图像分割	3
1.2 医学图像检测	4
二、 研究目标与研究内容	4
2.1 研究目标	4
2.2 研究内容	5
2.3 研究技术路线	5
三、主要科学问题及创新点	6
3.1 研究思路一：自动生成提示+不断自训练进行优化.....	6
3.2 研究思路二：冻住主骨干网络，加额外模块后进行微调	7
四、主要科研进展	7
4.1 已完成研究内容	7
4.2 已取得研究成果	10
4.3 已取得主要结论	11
五、未来研究计划	11
六、已取得研究成果	11
七、参考文献.....	12

一、 研究背景

1.1 医学图像分割

医学图像分割的目的是使图像中解剖或病理结构的变化更加清晰。它在计算机辅助诊断和智能医疗中发挥着至关重要的作用，极大地提高了诊断的效率和准确性。目前流行的医学图像分割任务包括肝脏和肝脏肿瘤分割，脑和脑肿瘤分割，视盘分割，细胞分割，肺分割和肺结节等。

为了帮助临床医生做出准确的诊断，有必要对医学图像中的一些关键目标进行分割，并从分割区域中提取特征。医学图像分割的早期方法通常依赖于边缘检测、模板匹配技术、统计形状模型、活动轮廓和传统机器学习技术。这些方法在一定程度上取得了不错的效果，但由于特征表示的困难，图像分割仍然是计算机视觉领域中最具挑战性的课题之一。特别是医学图像的特征提取比普通 RGB 图像更难，因为前者往往存在模糊、噪声、对比度低等问题。由于深度学习技术的快速发展，医学图像分割将不再需要手工制作的特征， CNN、Transformer 等深度学习网络成为图像处理和计算机视觉领域最热门的研究课题。由于用于特征学习的 CNN 对图像噪声、模糊、对比度等不敏感，对医学图像提供了很好的分割结果。

无监督的医学图像分割任务是医学影像分析领域的一个重要研究领域，其主要目标是在没有明确的像素级别标签或分割掩模的情况下，自动将医学图像中的不同结构和病变区域分割开来。传统的医学图像分割通常需要医学专家进行手动标注，这是一项费时费力的任务。手动标注不仅昂贵，还容易受到主观因素的影响，因此需要开发自动

化的方法来减轻工作量。

1.2 医学图像检测

医学图像的检测任务是医学影像分析领域中的一个关键问题，它涉及到在医学图像中准确识别和定位不同的病变、解剖结构或器官。这一领域的研究具有重要的临床应用意义，能够帮助医生更准确地进行诊断、治疗和监测患者的疾病状态。

近年来，人工智能和深度学习技术的快速发展为医学图像检测任务提供了新的机会。卷积神经网络（CNN）、Transformer 等深度学习模型已经在医学图像分析中取得了令人瞩目的成就，能够自动识别和定位图像中的关键特征。无监督的医学图像检测任务是医学影像分析领域中的一个重要研究方向，它旨在没有人工标签的情况下，自动识别和定位医学图像中的关键特征、结构或病变。随着医疗技术的不断进步，医学影像数据的数量迅速增加。X 射线、CT 扫描、MRI、超声等各种医学影像设备生成了大量的图像数据。传统的手动标注方法已经无法满足如此大规模的数据需求，因此无监督方法变得尤为重要。

二、 研究目标与研究内容

2.1 研究目标

随着医疗技术的不断进步，医学影像数据的数量迅速增加。X 射线、CT 扫描、MRI、超声等各种医学影像设备生成了大量的图像数据。传统的手动标注方法已经无法满足如此大规模的数据需求，因

此无监督方法变得尤为重要。大量的医学图像数据没有标签，这些未标记数据包含了有价值的信息。无监督方法可以帮助挖掘这些未标记数据中的潜在知识和模式，为医学研究提供更多的资源。我们计划研究一个无监督的医学图像分割和检测方法，应对不同的医学任务，发展自动化和智能化的医疗诊断。

2.2 研究内容

首先，利用 VLPM（大规模视觉语言预训练模型）学习医学图像中细胞核的丰富语义特征，以捕获其关键属性。探索如何有效地将 VLPM 的语义信息与医学图像中的细胞核进行关联，以支持零样本检测和分割。设计自动化提示生成管道，以利用 VLPM 的特性，以无监督方式生成用于细胞核检测的提示。解决文本编码器缺乏医学概念词汇的挑战，确保生成的提示能够准确描述核物质。

之后，研究“循环学习架构”，一种新颖的图像级别弱监督方法。循环学习被设计为在前端分类器和后端半监督部分之间循环共享知识，这使得整个系统能够充分提取图像级别标签中的潜在信息，并趋于更好的优化。

2.3 研究技术路线

首先，我们通过利用大规模视觉语言预训练模型（VLPM）来学习医学图像中细胞核的丰富语义特征，以捕获其关键属性。我们研究如何有效地将 VLPM 的语义信息与医学图像中的细胞核进行关联，

以支持零样本检测和分割。我们创建了一个自动化提示生成管道，以充分利用 VLPM 的特性，无监督地生成用于细胞核检测的提示。我们克服了文本编码器缺乏医学概念词汇的挑战，以确保生成的提示能够准确描述核物质。

随后，我们研究了一种新颖的图像级别弱监督方法，即“循环学习架构”。循环学习的设计思路是在前端分类器和后端半监督部分之间循环共享知识，使得整个系统能够充分提取图像级别标签中的潜在信息，并逐渐趋向更好的优化状态。

三、主要科学问题及创新点

为了实现无监督的医学图像检测和分割，我们经过学习和探索，设计了两个研究思路。

3.1 研究思路一：自动生成提示+不断自训练进行优化

利用自动提示设计方法充分利用 VLPM 的文本到图像对齐特性，实现对应领域最合适的属性文本词汇的自动生成，这将提供出色的可解释性。首先使用 BLIP 自动生成描述未见细胞核对象的属性词汇。这种方法避免了经验性的手动提示设计，并充分利用了 VLPM 的文本到图像对齐特性。然后，我们将这些属性词汇与医学名词，即“[形状][颜色][名词]”，结合起来创建检测提示。然后，将这些提示输入到 GLIP 中，以实现细胞核的零样本检测。通过 GLIP 的强大对象检索性能，我们可以获得初步框。这些初步框的精度相对较高，但在召回方面仍有相当大的改进空间。因此，我们可以进一步建立一个自训练

框架。对于 GLIP 生成的初步框，我们可以考虑使用无监督方法进行精炼，比如将其作为 YOLOX[7]的伪标签进行进一步训练，以迭代方式细化和优化预测的框。

3.2 研究思路二：冻住主骨干网络，加额外模块后进行微调

利用 VLPM 的文本到图像对齐特性，在不解耦其语言和文本对齐结构的前提下，添加一些额外的层来进行微调，使得模型能够快速适用于新的医学图像任务。比如，可以加目前流行的 adapter 结构，或者添加视觉提示调节器（vpt）等。这些模块相较于主骨干而言是轻量的，我们可以冻结主骨干网络，只训练这些额外添加的小模块，根据理论和我们已有的实验，这个方法能够高效提升视觉语言模型的可迁移性。

四、主要科研进展

4.1 已完成研究内容

为了验证研究思路一（自动生成提示+不断自训练进行优化）的可行性，我们首先研究了自训练方法在何种程度上能进行自我优化。

我们提出了一种灵活而通用的 MTL 方法，称为循环学习[2]，以

实现仅使用图像级别标签进行细胞核实例分割。循环学习将图像级别的细胞核实例分割任务分为两个任务：前端分类和后端半监督实例分割。前端任务专注于将粗粒度的图像级别注释转化为部分细胞核的伪掩码，而后端任务集中于通过半监督学习完成实例预测。最重要的是，循环学习利用 MIL[1]的优势，通过前端任务和后端任务之间的循环知识共享，促进了两者的优化。最终，循环学习同时改善了前端和后端的性能。理论分析证明，循环共享知识确保整个图像级别的弱监督框架收敛到更好的最优解。大量实验证明，循环学习的性能接近于完全监督方法，确实连接了图像级别标签和细胞核实例分割。循环学习的流程图如图 4.1：




Fig. 1. Illustration of the proposed method. (a) Cyclic learning, communicating tasks based on multi-task learning (MTL), circularly shares knowledge between the front-end task and the back-end task through weights until convergence. (b) The front-end trains a NN classifier f^C to generate pseudo masks using a NN interpreting method, then passes the pseudo seeds and backbone weights to the back-end. (c) The back-end conducts self-training with the pseudo seeds, each student f_i^S is initialized by the weights from f^C . The backbone weights of the best student f^S are passed to f^C to start a new cycle. The cycle stops when the whole system is converged.

图 4.1 循环学习流程图

图中展示了如何使用粗粒度的伪标签来不断自训练，不断优化得到更好的分割结果。

这个工作我们已经发表了 SCI 论文(IEEE TMI 期刊, IF=11.037)，结论获得了学界认同。这足以说明自训练方法能进行自我优化，尤其是对于医学图像中的密集物体分割、检测是非常有效的，而很多医学

图像确实具有密集特征，比如细胞核，一张图片内存在很多相似的细胞。

在这之后，我们进一步研究如何让模型自动生成提示。经过不断探索，我们使用 BLIP[4]自动生成描述未见过的细胞核对象的属性词汇，这一方法不仅避免了需要基于经验手动设计提示的过程，还充分发挥了 VLPM 的文本到图像对齐特性。接下来，我们将这些属性词汇与医学名词"[形状][颜色][名词]"相结合，用于创建检测提示。随后，将这些提示输入到 GLIP[5]中，以实现细胞核的零样本检测。通过 GLIP 出色的对象检索性能，我们能够获得初步的边界框，这些边界框在精度方面相对较高，但在召回方面仍然有改进的空间。至此，我们终于可以用上之前已经验证过的自训练模型，使用无监督方法对由 GLIP 生成的初步边界框进行进一步的精炼，例如将它们用作 YOLOX 的伪标签，并通过迭代方式对预测的边界框进行细化和优化。该方法的算法图如图 4.2。




Fig. 1. An overview of our zero-shot nuclei detection framework based on the frozen object-level VLPM GLIP. (a) Given the original target nouns of the task, prompts are designed automatically to avoid non-trivial empirical manual prompt engineering, based on the association binding of VLPM and the image-to-text VLPM BLIP. (b) A self-training strategy is further adopted to refine and polish the predicted boxes in an iterative manner. The automatically designed prompts are used by GLIP to generate the preliminary results as pseudo labels.

图 4.2 VLPMNuD 方法：自动生成提示，然后自训练得到 SOTA 结果。

最终，这个工作颇有成效，我们已经将其发表在 MICCAI 2023 会议上。并且，我们制作了海报，希望让更多人理解我们的方法，为学界做出一份贡献。

4.2 已取得研究结果

如 4.1 所述，我们经过两个阶段的研究工作，验证了我们猜想两个结论：

- 1) 自训练方法能进行自我优化，尤其是对于有密集特征的医学图像。
- 2) 自动生成提示+自训练方法可以高效实现无监督的医学图像检测和分割。

4.3 已取得主要结论

自训练方法能进行自我优化，尤其是对于有密集特征的医学图像。自动生成提示+自训练方法可以高效实现无监督的医学图像检测和分割。同时，现有的实验也侧面显示，提示词仍然有改进空间，我们可以再考虑如何让模型设计出更好的提示词，此外，我们也从实验中反思到，我们可以添加额外模块后进行微调。

五、未来研究计划

2023.12.~2024.1 文献调研，完成开题报告

2024.1.~2024.2 完成图像及数据的采集，对数据特征进行分析

2024.2~2024.8 算法设计与实现

2024.8~2024.10 算法评价与改进

2024.10~2024.12 实验结果整理，论文撰写

六、已取得研究成果

1.以共同作者身份发表了一篇 SCI 论文和一篇 EI 会议论文：

[1]Zhou, Y., **Wu, Y.**, Wang, Z., Wei, B., Lai, M., Shou, J., ... & Xu, Y. [J].
Cyclic Learning: Bridging Image-level Labels and Nuclei Instance
Segmentation.IEEE Transactions on Medical Imaging. (SCI, 研究论文,

共同一作，IF=11.037，Q1）；

[2]**Yongjian Wu**, Yang Zhou, et al. Zero-shot Nuclei Detection via Visual-Language Pre-trained Models [C]. Medical Image Computing and Computer Assisted Intervention – MICCAI 2023. Springer International Publishing.已接受 (EI, 研究论文, 共同一作, CCF-B, 医学图像 A 类)

2.为两篇论文公布了实验代码，发布在 [github](#)，目前正逐步收到其他学者的访问和使用。

3.为 MICCAI 会议论文制作了海报。

七、参考文献

1. F. Wan, C. Liu, W. Ke, X. Ji, J. Jiao, and Q. Ye, "C-MIL: Continuation multiple instance learning for weakly supervised object detection," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2019, pp. 2199–2208.
2. Zhou, Y., Wu, Y., Wang, Z., Wei, B., Lai, M., Shou, J., ... & Xu, Y. (2023). Cyclic Learning: Bridging Image-level Labels and Nuclei Instance Segmentation. IEEE Transactions on Medical Imaging.
3. Wu, Y., Zhou, Y., Saiyin, J., Wei, B., Lai, M., Shou, J., ... & Xu, Y. (2023). Zero-shot Nuclei Detection via Visual-Language Pre-trained Models. arXiv preprint arXiv:2306.17659.
4. Li, J., Li, D., Xiong, C., Hoi, S.: BLIP: bootstrapping language-image pre-training for unified vision-language understanding and generation. In: International Conference on Machine Learning, pp. 12888–12900. PMLR (2022).
5. Li, L. H., et al.: Grounded language-image pre-training. In: Proceedings of the

IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 10965–10975 (2022).

北京航空航天大学

博士研究生

《文献综述》

综述名称：无监督的医学图像分割和检测综述

姓 名：吴永健

学 号：BY2110209

指导教师：许燕

研究方向：医学图像处理

生物与医学工程学院

无监督的医学图像分割和检测综述

吴永健 指导老师：许燕

（北京航空航天大学生物与医学工程学院，北京）

摘要：医学图像分割和检测是医学领域中的重要研究方向，对疾病分析具有重要的临床价值。通常情况下，实现细胞核实例分割需要进行像素级的手动标注，实现细胞核物体检测的话类似，需要逐个细胞进行框选，尤其对于高密度的细胞核而言，这些标注过程既耗时又费力。为了减轻标注负担，势必需要研究对医学图像的弱监督乃至无监督的算法，为此我们做了一系列探索。我们尝试使用VLPM（视觉语言预训练）模型进行零样本细胞核检测和分割，使用自动设计的提示从GLIP生成初步结果作为伪标签，并以迭代方式改进预测结果。

关键词：物体检测；医学图像；图像分割；视觉语言模型

中图分类号：

文献标识

码：

Unsupervised Medical Image Segmentation and Detection

Abstract: Medical image segmentation and detection are important research directions in the field of medicine and hold significant clinical value for disease analysis. Typically, achieving cell nucleus instance

segmentation requires pixel-level manual annotations, and similar manual efforts are needed for cell nucleus object detection. Especially when dealing with high-density cell nuclei, these annotation processes are both time-consuming and labor-intensive. To alleviate the annotation burden, it is imperative to explore weakly supervised or even unsupervised algorithms for medical image analysis. To this end, we have undertaken a series of explorations.

We attempted zero-shot cell nucleus detection and segmentation using the Visual-Language Pre-trained Models (VLPM) model. We employed automatically designed prompts generated from the Grounded Language-Image Pre-training (GLIP) model to produce initial results as pseudo-labels and iteratively refined the predicted outcomes.

Keyword: Object detection; medical images; image segmentation; visual-language models.

一、引言

在医学图像处理领域，无监督的图像分割和检测技术一直备受关注。医学图像分割和检测是从不同影像学模态（如X射线、MRI、CT扫描等）中提取关键结构和病变区域的关键任务，对于临床诊断、疾病分析和治疗规划具有至关重要的作用。然而，传统的医学图像分割和检测方法通常需要大量的手动标注数据和监督学习框架，这限制了它们在实际医学应用中的广泛应用，因为手动标注是一项耗时且费力

的工作，同时对医学专业知识的需求也较高。

为了克服这些挑战，研究人员一直在努力开发无监督的医学图像分割和检测方法，这些方法可以减少对手动标注的依赖，提高自动化程度，并且在实际医学应用中具有巨大潜力。无监督的方法旨在从未标记或仅有部分标记的医学图像中提取信息，而无需详细的手动标注。

本综述旨在深入探讨无监督的医学图像分割和检测方法的最新进展，以及它们在医学领域的应用前景。我们将介绍一系列无监督技术，包括基于深度学习的方法、自监督学习、领域自适应技术以及基于视觉语言模型的方法。我们还将探讨这些方法的优点、挑战和局限性，并讨论它们在肿瘤检测、器官分割、病变定位等不同医学应用场景中的性能。最后，我们将展望未来，探讨无监督医学图像分割和检测领域的研究方向和潜在应用，以期为医学图像处理领域的研究人员和临床医生提供有益的参考和启发。

二、医学图像数据获取

医学图像数据获取获取方式主要有公开数据集、与医院和研究机构合作、与医院和研究机构合作这几种。

2.1 公开数据集

许多研究人员和机构已经创建了用于细胞核图像分割和检测的公开数据集。这些数据集通常包含了多种细胞类型和病理情境下的图像，以支持不同类型的研究。例如，"CellNet"、"Cell Tracking Challenge" 和 "MoNuSeg" 是一些常用的细胞核图像数据集，它们可在相关研究网站或数据共享平台上获取。对于本研究的主要任务场景：“物体检测”

和“图像分割”，这些公开的数据集完全能够支持。

2.2 与医院和研究机构合作

与医院或研究机构合作，可以获取实际临床病例的细胞核图像数据。这些图像可以通过医学影像设备（如显微镜、X 射线、MRI 等）获得，通常需要确保符合隐私法规和伦理准则。

首先找到合适的医院或研究机构，特别是那些与我们研究领域相关的机构。可以通过学术网络、科学会议、研究论坛等途径建立联系。接着，与医院或研究机构建立合作伙伴关系，明确研究目标、方法和预期成果。这通常需要与医院管理层、研究机构主管或临床合作协调员进行沟通。在获取临床病例数据时，通常需要进行伦理审查，并获得伦理委员会的批准。此外，需要确保数据隐私的保护，遵循相关的隐私法规。此外，最好与医院或研究机构签署数据使用协议，明确数据的使用条件、范围和期限。协议通常包括数据共享、数据处理、数据安全等方面的规定。一旦获得数据使用许可，可以开始获取实际临床病例的细胞核图像数据。这可能涉及到从医院信息系统或研究数据库中提取数据，并进行必要的图像处理和标注。

2.3 自行采集图像

自行采集细胞核图像，使用显微镜、荧光显微镜、电子显微镜等专业仪器。这需要在实验室或医疗机构内进行，并按照特定的采集协议和方法。在实践过程中，我们可以查看学校是否有与医学、生物学或生命科学相关的实验室或研究中心。这些机构通常配备了显微镜和其他必要的设备。联系相关的研究机构或负责人，了解是否可以获得

访问权限。某些情况下，可以考虑在实验室实习或加入与细胞核图像相关的研究项目。这将提供机会在专业环境中获得细胞核图像数据。当学校有合作伙伴或研究机构具备所需的设备，但不在学校地理位置附近，可以考虑与他们建立远程合作，通过远程访问设备进行数据采集。此外，还要探索可能获得研究资金的机会，以购买或租赁所需的仪器，或者寻找资助项目，以便在其他实验室或机构中进行数据采集。

总之，我们可以采取多种方法来获取细胞核图像数据，包括与合作伙伴合作、利用公开数据集和自行采集。重要的是要寻求适应我们研究需求的解决方案，并确保在获取数据时遵守相关法规和伦理准则。

三、医学图像检测和分割的弱监督方法

3.1 医学图像目标检测的弱监督方法

弱监督目标检测（WSOD）在减少大量标签成本方面具有实际价值。通常，它通过两阶段流程来解决，即首先将图像分解为一系列区域提议，然后采用多实例学习（MIL）来迭代进行提议选择。开创性的工作是 WSDDN^[1]，它利用 MIL 将 WSOD 转化为分类问题，并构建了一个端到端可训练的深度网络。尽管有效，但已被证明容易导致不完整的物体定位。为了解决这个问题，工作^[2]通过构建两个上下文感知引导模型（加法模型和对比模型）来改善定位。唐等人^[3]通过引入细化分支并设计了一种新颖的 OICR 策略来升级 WSDDN。然而，OICR 在很大程度上依赖于目标检测结果的初始质量，限制了其有效性。因此，一些基于 OICR 的方法专注于探索上下文信息^{[4][5][6][7][8]}，或提议优化^{[9][10]}以达到更好的初始化。韦等人⁴引入了分割置信度图

以扩大边界框。李等人⁸通过与生成对抗分割模块合作，为检测和分割任务提供了综合解决方案。工作^[11]学习了一个具体的 DropBlock，以自适应地擦除有判别性的区域。程等人⁹通过挖掘更多高质量的提议和困难样本，专注于选择更好的初始提议。张等人⁷将图卷积网络集成到检测网络中，以充分探索两级上下文以促进性能。此外，还有一些先进的工作^{[12][13][14][15]}提出了更好的训练策略。张等人¹⁴首先估计图像难度，然后引入了一种新颖的课程学习策略，逐渐训练出一个强大的检测器。王等人¹²提出了一个最小熵潜在模型，通过评估物体定位的随机性来减轻检测器的模糊性。黄等人^[16]希望通过学习全面的注意力和自我蒸馏来实现 WSOD，将同一图像在多种变换下的丰富特征聚合起来，突出显示整个物体。还有一些方法旨在为训练强大的物体检测器获取更多的正实例。唐等人⁶执行提议聚类学习以挖掘所有可能的实例。林等人则旨在通过估计空间和外观相似性来发现更多的正实例。最近，工作^[17]还利用了经过良好注释的辅助数据集来学习边界框调整器，以改善物体定位。

尽管基于 OICR 的方法已经被证明对 WSOD 非常重要，但它们忽视了 WSOD 的致命缺陷（即不一致的学习过程和对定位质量的无感知性）。这些问题一直是长期存在但仍未解决的难题。为了填补这方面的空白，本文以端到端的自监督方式构建了一种新颖的不变性和等变性网络，无需额外的监督。

3.2 医学图像图像分割的弱监督方法

为了解决像素级数据稀缺的问题，界内学者们已经提出了用于语

义分割和实例分割的弱监督方法。一些方法尝试使用不精确的标注，例如图像级标签^{[18][19]}、涂鸦^{[20][21]}和边界框^{[22][23]}。其中，图像级标签最容易获取，许多相关的弱监督方法利用卷积神经网络（CNN）解释方法^{[24][25][26]}。其他一些方法试图利用半监督框架^{[27][28]}中的不完整标注，如自我训练^{[29][30]}。对于密集实例分割，点^[31]、涂鸦^[32]、边界框^[33]和图像级标签^[34]都被用作弱监督。

目前，大多数图像级弱监督方法是为语义分割而提出的，例如 OAA^[35]、MCIS^[36]和 DRS^[37]。在自然场景中，Ahn 等人提出了 IRNet，仅使用图像级标签进行实例分割^[38]。对于组织病理图像，Xue 等人采用多实例学习技术提出了 CAMEL 用于语义分割^[39]。Gu 等人提出了一种基于图像级标签和 Transformer 的图像级语义分割方法，用于腺体^[40]。类似地，SwinMIL 是一种多实例学习方法，也是在组织病理图像的图像级语义分割中首次利用 Transformer 的方法^[41]。

然而，在组织病理图像中，图像级标注尚未被充分利用以进行细胞核实例分割，其中细胞核的空间密度甚至更高。为自然实例分割设计的图像级方法²⁴²⁵在组织病理图像中的细胞核实例分割表现不佳。

四、医学图像检测 and 分割的无监督方法

4.1 医学图像目标检测的无监督方法

在医学图像处理领域，细胞核检测在生物医学研究和临床应用的各个领域起着关键作用^[42]。尽管已经提出了用于这一任务的全监督方法^{[43][44][45]}和弱监督方法，但标注仍然是一项耗时且昂贵的工作。为了解决上述问题，已经提出了几种无监督方法，包括基于阈值的方法

[46][47]、自监督方法^[48]和基于领域适应的方法^[49]。在这些方法中，领域适应方法是主流的，并通过对齐源域和目标域来实现适应性，已经证明具有良好的性能⁴⁹。然而，当前的无监督方法在模型设计过程中存在强烈的经验设计，并引入了主观偏见，因此当前的无监督方法可能导致次优结果。

然而，新开发的大规模视觉语言预训练模型（VLPMs）为另一种可能的无监督学习范式提供了可能性^{[50][51]}。VLPM 从互联网获取的大量文本-图像对中学习了文本和图像的对齐特征，使学到的视觉特征具有丰富的语义、通用性和可传递性。基于 VLPM 的零样本学习方法用于下游任务，如文本驱动的图像处理^[52]、图像字幕^[53]、视图合成^[54]和目标检测^[55]，取得了出色的成绩。在 VLPM 中，基于对象级别预训练的 Grounded Language-Image Pre-training (GLIP) 模型⁵⁵，甚至可以在零样本对象检测和短语定位任务中与全监督方法媲美。

尽管 VLPM 已用于自然场景中的对象检测，但通过 VLPM 在 H&E 图像上进行零样本细胞核检测仍未被充分探索。医学 H&E 图像与用于预训练的自然图像之间存在显著的领域差异，这使得这项任务具有挑战性。人们想知道 VLPM 是否能够通过语义驱动的提示直接预测细胞核检测，从而建立一种简洁、明确但更高效和可传递的无监督系统，用于无标签细胞核检测。

在此基础上，一些学者的目标是建立基于 VLPM 的零样本细胞核检测框架。然而，直接应用 VLPM 于此任务面临两个挑战。(1) 由于医学图像与用于预训练的大量文本-图像对之间存在差距，文本编码

器可能缺乏医学概念词汇的先验知识，因此为零样本检测设计提示是一项具有挑战性的任务。(2) 与自然图像中的对象不同，H&E 染色图像中细胞核的高密度和特殊形态可能导致仅通过提示在零样本传输过程中出现未检测、误检和重叠。

为了解决第一个挑战，山田等人已经分析并揭示，在大量文本-图像对的预训练下，VLPM 不论图像领域如何，都建立了对象与其语义属性之间的强关联，即关联的属性文本可以通过 VLPM 充分描述图像中对应的对象^[56]。因此，通过构建适当的属性文本，VLPM 可以以无标签方式检测未见过的医学对象是可行的。手动提示是一个繁琐且主观的过程，可能导致相当大的偏差。然而，VLPM 网络 BLIP⁵³ 具备为图像生成自动描述的能力。

4.2 医学图像分割的无监督方法

随着对避免过度依赖人工专家标注的强调增加，研究人员一直在探索医学图像分割的无监督学习方法。许多最近的工作都集中在使用更少的数据进行训练^{[57][58][59][60]}。更进一步，SSL-ALPNet^[61] 提出了直接从 Felzenswalb 分割生成的伪标签中学习。它确实消除了对专家标签的依赖，使其成为一种无监督学习方法，尽管训练过程与监督学习相似。DCGN^[62] 使用受限高斯混合模型对组织病理学图像中的像素表示进行无监督聚类。它利用了一个先验，即不同的组织类型通常对应不同的颜色，但这在其他医学图像模态下可能不再成立。基于图谱的无监督学习是无监督医学图像分割的另一个有前途的方向^{[63][64]}。与传统方法^{[65][66][67]}相比，这些基于深度学习的版本取得了更好的结

果。然而，它们仍然存在前面提到的一些限制。此外，由于需要空间配准，它们更适用于具有清晰定义结构且在个体之间变化较小的器官（例如大脑），而对高度可变形的身体部位的适用性较低。

五、医学图像数据获取及分割方法研究未来研究方向

综合以上文献梳理，该领域未来发展方向有：

1. 利用自动提示设计方法充分利用 VLPM 的文本到图像对齐特性，实现对应领域最合适的属性文本词汇的自动生成，这将提供出色的可解释性。首先使用 BLIP 自动生成描述未见细胞核对象的属性词汇。这种方法避免了经验性的手动提示设计，并充分利用了 VLPM 的文本到图像对齐特性。然后，我们将这些属性词汇与医学名词，即 "[形状][颜色][名词]"，结合起来创建检测提示。然后，将这些提示输入到 GLIP 中，以实现细胞核的零样本检测。通过 GLIP 的强大对象检索性能，我们可以获得初步框。这些初步框的精度相对较高，但在召回方面仍有相当大的改进空间。因此，我们可以进一步建立一个自训练框架。对于 GLIP 生成的初步框，我们可以考虑使用无监督方法进行精炼，比如将其作为 YOLOX 的伪标签进行进一步训练，以迭代方式细化和优化预测的框。

2. 利用 VLPM 的文本到图像对齐特性，在不解耦其语言和文本对齐结构的前提下，添加一些额外的层来进行微调，使得模型能够快速适用于新的医学图像任务。比如，可以加目前流行的 adapter 结构，或者添加视觉提示调节器（vpt）等。这些模块相较于主骨干而言是

轻量的，我们可以冻结主骨干网络，只训练这些额外添加的小模块，根据理论和我们已有的实验，这个方法能够高效提升视觉语言模型的可迁移性。

参考文献：

- [1] H. Bilen and A. Vedaldi, "Weakly supervised deep detection networks," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2016, pp. 2846–2854.
- [2] V. Kantorov, M. Oquab, M. Cho, and I. Laptev, "ContextLocNet: Context-aware deep network models for weakly supervised localization," in Proc. Eur. Conf. Comput. Vis., Springer, 2016, pp. 350–365.
- [3] P. Tang, X. Wang, X. Bai, and W. Liu, "Multiple instance detection network with online instance classifier refinement," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2017, pp. 2843–2851.
- [4] Y. Wei et al., "TS2C: Tight box mining with surrounding segmentation context for weakly supervised object detection," in Proc. Eur. Conf. Comput. Vis., 2018, pp. 434–450.
- [5] S. Kosugi, T. Yamasaki, and K. Aizawa, "Object-aware instance labeling for weakly supervised object detection," in Proc. IEEE Int. Conf. Comput. Vis., 2019, pp. 6064–6072.
- [6] P. Tang et al., "PCL: Proposal cluster learning for weakly supervised object detection," IEEE Trans. Pattern Anal. Mach. Intell., vol. 42, no. 1, pp. 176–191, Jan. 2020.
- [7] D. Zhang et al., "Weakly supervised object detection using proposal-and semantic-level relationships," IEEE Trans. Pattern Anal. Mach. Intell., vol. 44, no. 6, pp. 3349–3363, Jun. 2022.
- [8] X. Li et al., "Weakly supervised object detection with segmentation collaboration," in Proc. IEEE/CVF Int. Conf. Comput. Vis., 2019, pp. 9735–9744.
- [9] G. Cheng et al., "High-quality proposals for weakly supervised object detection," IEEE Trans. Image Process., vol. 29, pp. 5794–5804, Apr. 2020, doi:10.1109/TIP.2020.2987161.
- [10] P. Tang et al., "Weakly supervised region proposal network and object detection," in Proc. Eur. Conf. Comput. Vis., 2018, pp. 352–368.
- [11] Z. Ren et al., "Instance-aware, context-focused, and memory-efficient weakly supervised object detection," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2020, pp. 10598–10607.
- [12] F. Wan, P. Wei, J. Jiao, Z. Han, and Q. Ye, "Min-entropy latent model for weakly supervised object detection," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2018, pp. 1297–1306.
- [13] F. Wan, C. Liu, W. Ke, X. Ji, J. Jiao, and Q. Ye, "C-MIL: Continuation multiple instance learning for weakly supervised object detection," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2019, pp. 2199–2208.
- [14] X. Zhang, J. Feng, H. Xiong, and Q. Tian, "Zigzag learning for weakly supervised object detection," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2018, pp. 4262–4270.
- [15] G. Wang, X. Zhang, Z. Peng, X. Tang, H. Zhou, and L. Jiao, "Absolute wrong makes better: Boosting weakly supervised object detection via negative deterministic information," 2022, arXiv:2204.10068.
- [16] Z. Huang, Y. Zou, B. Kumar, and D. Huang, "Comprehensive attention self-distillation for weakly-supervised object detection," in Proc. Adv. Neural Inf. Process. Syst., 2020, pp. 16797–16807.
- [17] X. Zhang, J. Feng, H. Xiong, and Q. Tian, "Zigzag learning for weakly supervised object detection," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2018, pp. 4262–4270.
- [18] Y. Wei, H. Xiao, H. Shi, Z. Jie, J. Feng, and T. S. Huang, "Revisiting dilated convolution: A

- simple approach for weakly- and semi-supervised semantic segmentation," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018, pp. 7268–7277.
- [19] Y. Yao, T. Chen, G.-S. Xie, C. Zhang, F. Shen, Q. Wu, Z. Tang, and J. Zhang, "Non-salient region object mining for weakly supervised semantic segmentation," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021, pp. 2623–2632.
- [20] D. Lin, J. Dai, J. Jia, K. He, and J. Sun, "Scribblesup: Scribble-supervised convolutional networks for semantic segmentation," in Proceedings of the IEEE conference on computer vision and pattern recognition, 2016, pp. 3159–3167.
- [21] M. Tang, A. Djelouah, F. Perazzi, Y. Boykov, and C. Schroers, "Normalized cut loss for weakly-supervised CNN segmentation," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018, pp. 1818–1827.
- [22] C.-C. Hsu, K.-J. Hsu, C.-C. Tsai, Y.-Y. Lin, and Y.-Y. Chuang, "Weakly supervised instance segmentation using the bounding box tightness prior," in Advances in Neural Information Processing Systems, vol. 32, pp. 6586–6597, 2019.
- [23] A. Arun, C. Jawahar, and M. P. Kumar, "Weakly supervised instance segmentation by learning annotation consistent instances," in European Conference on Computer Vision. Springer, 2020, pp. 254–270.
- [24] Y. Zhou, Y. Zhu, Q. Ye, Q. Qiu, and J. Jiao, "Weakly supervised instance segmentation using class peak response," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018, pp. 3791–3800.
- [25] W. Ge, S. Guo, W. Huang, and M. R. Scott, "Label-penet: Sequential label propagation and enhancement networks for weakly supervised instance segmentation," in Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019, pp. 3345–3354.
- [26] J. Ahn, S. Cho, and S. Kwak, "Weakly supervised learning of instance segmentation with inter-pixel relations," in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019, pp. 2209–2218.
- [27] Q. Li, A. Arnab, and P. H. Torr, "Weakly- and semi-supervised panoptic segmentation," in Proceedings of the European Conference on Computer Vision (ECCV), 2018, pp. 102–118.
- [28] F. A. Guerrero-Pena, P. D. M. Fernandez, T. I. Ren, and A. Cunha, "A weakly supervised method for instance segmentation of biological cells," in Domain Adaptation and Representation Transfer and Medical Image Learning with Less Labels and Imperfect Data. Springer, 2019, pp. 216–224.
- [29] E. Riloff and J. Wiebe, "Learning extraction patterns for subjective expressions," in Proceedings of the 2003 conference on Empirical methods in natural language processing, 2003, pp. 105–112.
- [30] Y. Zhou, H. Chen, H. Lin, and P.-A. Heng, "Deep semi-supervised knowledge distillation for overlapping cervical cell instance segmentation," in International Conference on Medical Image Computing and Computer-Assisted Intervention, Springer, 2020, pp. 521–531.
- [31] H. Qu, P. Wu, Q. Huang, J. Yi, Z. Yan, K. Li, G. M. Riedlinger, S. De, S. Zhang, and D. N. Metaxas, "Weakly supervised deep nucleus segmentation using partial points annotation in histopathology images," IEEE Transactions on Medical Imaging, vol. 39, no. 11, pp. 3655–3666, 2020.
- [32] H. Lee and W.-K. Jeong, "Scribble2label: Scribble-supervised cell segmentation via self-generating pseudo-labels with consistency," in International Conference on Medical Image Computing and Computer-Assisted Intervention, Springer, 2020, pp. 14–23.
- [33] L. Yang, Y. Zhang, Z. Zhao, H. Zheng, P. Liang, M. T. Ying, A. T. Ahuja, and D. Z. Chen, "Boxnet: Deep learning-based biomedical image segmentation using boxes only annotation," arXiv preprint arXiv:1806.00593, 2018.
- [34] A. Bilodeau, C. V. Delmas, M. Parent, P. De Koninck, A. Durand, and F. Lavoie-Cardinal, "Microscopy analysis neural network to solve detection, enumeration and segmentation from image-level annotations," Nature Machine Intelligence, vol. 4, no. 5, pp. 455–466, 2022.
- [35] P.-T. Jiang, Q. Hou, Y. Cao, M.-M. Cheng, Y. Wei, and H.-K. Xiong, "Integral object mining via online attention accumulation," in Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019, pp. 2070–2079.
- [36] G. Sun, W. Wang, J. Dai, and L. Van Gool, "Mining cross-image semantics for weakly supervised semantic segmentation," in European conference on computer vision. Springer, 2020,

pp. 347-365.

- [37] B. Kim, S. Han, and J. Kim, "Discriminative region suppression for weakly-supervised semantic segmentation," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 2, 2021, pp. 1754-1761.
- [38] J. Ahn, S. Cho, and S. Kwak, "Weakly supervised learning of instance segmentation with inter-pixel relations," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019, pp. 2209-2218.
- [39] G. Xu, Z. Song, Z. Sun, C. Ku, Z. Yang, C. Liu, S. Wang, J. Ma, and W. Xu, "CAMEL: A weakly supervised learning framework for histopathology image segmentation," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2019, pp. 10682-10691.
- [40] W. Gu, S. Wang, S. Zhao, L. Wan, and Z. Zhu, "HistoSegRest: A weakly supervised learning method for histopathology image segmentation," in *2022 the 5th International Conference on Image and Graphics Processing (ICIGP)*, 2022, pp. 189-195.
- [41] Z. Qian, K. Li, M. Lai, E. I. Chang, B. Wei, Y. Fan, Y. Xue et al., "Transformer-based multiple instance learning for weakly supervised histopathology image segmentation," *arXiv preprint arXiv:2205.08878*, 2022.
- [42] Gleason, D.F.: Histologic grading of prostate cancer: a perspective. *Hum. Pathol.* 23(3), 273–279 (1992).
- [43] Graham, S., et al.: Hover-net: simultaneous segmentation and classification of nuclei in multi-tissue histology images. *Med. Image Anal.* 58, 101563 (2019).
- [44] Mahanta, L.B., Hussain, E., Das, N., Kakoti, L., Chowdhury, M.: IHC-net: a fully convolutional neural network for automated nuclear segmentation and ensemble classification for allred scoring in breast pathology. *Appl. Soft Comput.* 103, 107136 (2021).
- [45] Yi, J., et al.: Multi-scale cell instance segmentation with keypoint graph-based bounding boxes. In: Shen, D., et al. (eds.) *MICCAI 2019. LNCS*, vol. 11764, pp. 369–377. Springer, Cham (2019). doi: 10.1007/978-3-030-32239-7_41
- [46] Jiao, S., Li, X., Lu, X.: An improved Otsu method for image segmentation. In: *2006 8th International Conference on Signal Processing*, vol. 2. IEEE (2006).
- [47] Mouelhi, A., Rmili, H., Ali, J.B., Sayadi, M., Doghri, R., Mrad, K.: Fast unsupervised nuclear segmentation and classification scheme for automatically red cancer scoring in immunohistochemical breast tissue images. *Comput. Methods Prog. Biomed.* 165, 37–51 (2018).
- [48] Sahasrabudhe, M., et al.: Self-supervised nucleus segmentation in histopathological images using attention. In: Martel, A.L., et al. (eds.) *MICCAI 2020. LNCS*, vol. 12265, pp. 393–402. Springer, Cham (2020). doi:10.1007/978-3-030-59722-1_38.
- [49] Le Bescond, L., et al.: Unsupervised nucleus segmentation using spatial organization priors. In: Wang, L., Dou, Q., Fletcher, P.T., Speidel, S., Li, S. (eds) *Medical Image Computing and Computer Assisted Intervention – MICCAI 2022. MICCAI 2022. LNCS*, vol. 13432, pp. 325–335. Springer, Cham (2022). doi:10.1007/978-3-031-16434-7_32.
- [50] Jia, C., et al.: Scaling up visual and vision-language representation learning with noisy text supervision. In: *International Conference on Machine Learning*, pp. 4904–4916. PMLR (2021).
- [51] Radford, A., et al.: Learning transferable visual models from natural language supervision. In: *International Conference on Machine Learning*, pp. 8748–8763. PMLR (2021).
- [52] Patashnik, O., Wu, Z., Shechtman, E., Cohen-Or, D., Lischinski, D.: Styleclip: text-driven manipulation of stylegan imagery. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 2085–2094 (2021).
- [53] Li, J., Li, D., Xiong, C., Hoi, S.: BLIP: bootstrapping language-image pre-training for unified vision-language understanding and generation. In: *International Conference on Machine Learning*, pp. 12888–12900. PMLR (2022).
- [54] Jain, A., Tancik, M., Abbeel, P.: Putting nerf on a diet: semantically consistent few-shot view synthesis. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 5885–5894 (2021).
- [55] Li, L. H., et al.: Grounded language-image pre-training. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 10965–10975 (2022).
- [56] Yamada, Y., Tang, Y., Yildirim, I.: When are lemons purple? The concept association bias of CLIP. *arXiv preprint arXiv:2212.12043* (2022).
- [57] Mondal, A. K., Dolz, J., & Desrosiers, C. Few-shot 3D multi-modal medical image

- segmentation using generative adversarial learning. arXiv preprint arXiv:1810.12241 (2018).
- [58] Ouyang, C., Kamnitsas, K., Biffi, C., Duan, J., & Rueckert, D. (2019). Data efficient unsupervised domain adaptation for cross-modality image segmentation. In *Medical Image Computing and Computer Assisted Intervention—MICCAI 2019: 22nd International Conference, Shenzhen, China, October 13–17, 2019, Proceedings, Part II*, 22, 669–677. Springer.
- [59] Yu, H., et al. (2020). Foal: Fast online adaptive learning for cardiac motion estimation. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 4313–4323.
- [60] Chen, C., et al. (2020). Realistic adversarial data augmentation for MR image segmentation. In *Medical Image Computing and Computer Assisted Intervention—MICCAI 2020: 23rd International Conference, Lima, Peru, October 4–8, 2020, Proceedings, Part I* 23, 667–677. Springer.
- [61] Ouyang, C., et al. (2020). Self-supervision with superpixels: Training few-shot medical image segmentation without annotation. In *Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXIX* 16, 762–780. Springer.
- [62] Nan, Y., et al. (2022). Unsupervised tissue segmentation via deep constrained gaussian network. *IEEE Transactions on Medical Imaging*, 41, 3799–3811.
- [63] Zhao, A., Balakrishnan, G., Durand, F., Guttag, J. V., & Dalca, A. V. (2019). Data augmentation using learned transformations for one-shot medical image segmentation. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 8543–8553.
- [64] Wang, S., et al. (2020). Lt-net: Label transfer by learning reversible voxel-wise correspondence for one-shot medical image segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 9162–9171.
- [65] Isgum, I., et al. (2009). Multi-atlas-based segmentation with local decision fusion—application to cardiac and aortic segmentation in CT scans. *IEEE Transactions on Medical Imaging*, 28, 1000–1010.
- [66] Aljabar, P., Heckemann, R. A., Hammers, A., Hajnal, J. V., & Rueckert, D. (2009). Multi-atlas based segmentation of brain images: atlas selection and its effect on accuracy. *Neuroimage*, 46, 726–738.
- [67] Iglesias, J. E., & Sabuncu, M. R. (2015). Multi-atlas segmentation of biomedical images: a survey. *Medical image analysis*, 24, 205–219.